

8年
软件研发

1.7年
AI 应用工程

4条
业务线主导

70%→80%
评测分提升

个人简介

LLM 应用算法工程师,负责 Plaud AI 背后的 AI 服务,覆盖录音总结、RAG 问答、项目级摘要、MCP / Agent 集成四条业务线。纵向贯穿 Model Hub 底层路由 / 容错 / 可观测性 到上层 Multi-Agent 业务编排 全栈。核心沉淀:LLM 工程化、Agent 健壮性设计、评测体系、异构模型路由、Temporal 异步编排、K8s 生产部署。

工作经历

2020.06 - 至今 · 从前端到 AI 应用全栈

2020 前端工程基础

腾讯文档 2 年,建立复杂系统架构与工程效能习惯

2023 AI 系统转向

NUS AI 系统硕士,微软 LLM 研究,开始 LLM 工程实践

2024 Agent 编排

Plaud AI,从单链路优化到 Multi-Agent 系统主导

Plaud Project Summary · Multi-Agent 项目级摘要

独立负责,端到端

- 角色** 从 0 到 1 独立交付并上线。聚合一个项目下多份录音与文档,产出结构化项目报告,支持总结 / 对比 / 进度跟踪三种策略。覆盖 API → Handler → Checkpoint → Agent 编排 → Temporal 异步回传全栈。
- 动作** 按 token 量静态路由 ONE-PASS / MAP-REDUCE;主链串成「分析文件关系 → 生成大纲 + 抽 RAG 查询 → 检索补全 → 合成 → 审阅润色」工具流;大内容委托 map-reduce 予 Agent,先按文件并行抽取 section、再按 section 维度并行合并(维度转换去重),最后组装;并发写 state 用 reducer 合并防数据竞争。System prompt 定序 + 工具限流防死循环,review 后锁写防覆盖。Temporal Signal 异步回传,K8s SIGTERM 后先摘流(健康检查转 503)、排空在途任务再退出,保证长任务不被腰斩。
- 结果** LLM 内短 ID 省 token,出口三级模糊匹配还原(精确 → endswith → contains)映射回文件名,纯 Python 确定性处理。自研 G-Eval 评测体系,三种策略各配加权维度,每维度多采样(N=8)取均值,LLM-as-Judge(gpt-5.1)让 prompt 改动可量化对比。

Plaud Model Hub · 统一 LLM 调用基础设施层

核心贡献者

- 角色** Plaud AI Platform 的统一大模型调用层,通过 Logical Model / Endpoint / Provider 三层抽象屏蔽供应商差异,内部托管路由 / 容错 / 可观测性。
- 动作** 自研 Adaptive Weight 插件:滑动窗口渐进降权替代二值切流,按 429 率连续调权;OpenAI ↔ Anthropic / GenAI 双向适配,一份代码路由异构 Provider;模型列表 + 环路检测,元数据回写命中模型,降级路径可审计;Hub 包成 LangChain Runnable,业务直用链式 API;凭证 / 路由 / 插件通过 AppConfig 热更新。
- 结果** 解决 GSU+PayGo 下成本飙升 + 连锁 429。基类支持 Chat / Embedding,新增 Claude on Vertex AI。补齐三个参数管理 API,元数据可追成本。后端支持 YAML / JSON。

Plaud Summary · AI 录音总结服务

核心业务,全链路参与

- 角色** 把录音转写变成结构化 Markdown 笔记。覆盖海外 / CN 多 Region、多语种、50+ 业务场景。
- 动作** 「JSON → Reasoning One-Shot」链路重构:Markdown 直出释放 reasoning budget,配合 map-reduce、十余场景模板,已上线为默认管道。PFS 走 Framework → Sections → Polish 三步产出专家级笔记;框架步动态生成结构,分节步并行抽取(max_concurrency=7),润色步用 diff 比例防摆烂。Summary Card:LLM 生成 HTML → 浏览器渲染 → S3 归档。
- 结果** 自研 G-Eval 评估体系让 Prompt 改动可量化对比,评测分从 30% 提升至 70+%,PFS 管道进一步提升至 80+%。User-Custom Prompt 污染治理:System Prompt 定优先级 + 正则 + 小模型复核防出处泄露。向量相似度推荐模板;社区模板走审核状态机并版本管理。

Plaud Ask · RAG 问答

独立从 0 到 1 交付

- 角色** 独立从 0 到 1 交付 Integration Skills(Gmail + Google Docs + Slack):LLM 起草卡片、用户审阅后经 MCP 投递;覆盖 API → Handler → MCP Client 全栈。
- 动作** 卡片不污染 LLM 上下文:分「展示」与「推理」两通道。配置驱动 Handler + 双状态机:注册表 + builder 替代 if/elif,新技能追加配置;卡片态 / 投递态分离,部分失败仍标成功。Email 链:「转写 → Markdown → PDF → 投递」。
- 结果** S3 key 换 presigned URL 让远端 LLM 读图;1500+ 行单测覆盖原子性 / OAuth / 部分失败。

专注 AI 工程化工具与生产力增强,从需求提炼到设计、实现、部署一人完成全流程。GitHub 累计 500+ stars。

text-to-diagrams	Python · 纯文本 → 带 SVG 配图 Markdown · Claude Skill	★ 200+	kami	排版系统 · 简历/白皮书/Slides HTML → PDF · Claude Skill	★ 180+
RAG System	Python · 企业知识库检索 · LlamaIndex + Ragas	★ 50+	Plaud Slides	Python · 录音总结 → 演示文稿生成器 · NiceGUI	★ 40+
Blog	Markdown · 技术博客 · AI / Agent / 前端架构	★ 30+	Weekly	周刊 · AI 工程实践与工具追踪	★ 20+

设计哲学

text-to-diagrams 核心判断: 别让 LLM 算坐标。10 种公式 / 确定性布局走纯 Python, 7 种自由拓扑走 LLM 改 SVG。两条防幻觉护栏: 锚点 ID 对照大纲校验、编造则重生成; SVG 输出纯 Python 几何校验, 有问题才反馈重试。可插拔第二产物形态(Summary Infographic): 结论先行文本抽成 8 种原语, 按「注意力金字塔」纯 Python 拼成 HTML 信息图。

AI 判断与行动

2024.10 提前布局 Agent 编排	2024.04 押注 RAG 工程化	2024.01 LLM 因果推理研究
加入 Plaud AI 时判断录音总结会从单链路走向项目级聚合,主动承接 Project Summary 从 0 到 1,成为团队首个 Multi-Agent 生产系统。	在硕士项目中落地查询转换、混合搜索、Graph 增强等策略,用 Ragas 量化评估迭代配置,建立 RAG 系统性能优化方法论。	微软实习主导 LLM4Causality 研究,设计专业推理 Prompts,量化评估 LLM 在复杂因果识别上的优越性,证明 LLM 可超越传统方法。

核心能力

LLM 应用工程化	LangChain、LangGraph、DeepAgents、LlamaIndex、MCP、Langfuse、Ragas。Gemini (Vertex AI)、GPT (OpenAI)、Claude (Bedrock)、豆包 / 通义(Model Hub)。自研评测体系(G-Eval)、自研 Adaptive Weight 路由插件。
Agent 健壮性设计	System prompt 定序、工具限流防死循环、review 后锁写防覆盖、文件预处理先生成 file_summary 压低 context。Citation 引用溯源: LLM 内短 ID 省 token, 出口三级模糊匹配还原, 纯 Python 确定性处理。
异构模型路由	OpenAI ↔ Anthropic / GenAI 双向适配, 一份代码路由异构 Provider。Logical Model / Endpoint / Provider 三层抽象。Fallback 增强: 模型列表 + 环路检测, 降级路径可审计。
K8s 生产部署	Docker、K8s、Supervisor、Temporal、Kafka (MSK)、AWS AppConfig。SIGTERM 后先摘流(健康检查转 503)、排空在途任务再退出, 保证长任务不被腰斩。OpenTelemetry、Langfuse、自定义业务指标。
全栈开发基础	Python、TypeScript / JavaScript、SQL、C#。FastAPI、Flask、Gunicorn / Uvicorn、NiceGUI、Gradio。AWS S3、OpenSearch、Milvus、pgvector、Redis、MySQL、MongoDB、Snowflake、Redshift。uv、Ruff、MyPy、Pre-commit、Git、Linux。

教育背景

新加坡国立大学(NUS) · 人工智能系统 · 硕士 · 2023.08 - 2024.10

太原理工大学 · 软件工程 · 本科 · 2016.09 - 2020.07