梁柱

13485492580 | pillarliang21@gmail.com | github.com/pillarliang | Blog: pillarliang.github.io

教育背景

学校	专业 / 学位	时间
新加坡国立大学 (NUS)	人工智能系统 · 硕士	2023.08 – 2024.10
太原理工大学	软件工程 · 本科	2016.09 – 2020.07

工作经历

负责阿里云百炼国际站（Model Studio）的 大模型评测、客户方案验证与技术支持，帮助海外客户选择并接入适合业务场景的模型；同时参与 Qwen 模型商业授权合作，推动客户需求与模型能力、部署方式及商业方案对齐。

阿里云（北京）科技有限公司 | GenAI SA (2026.08 – 至今)

- **模型评测与选型**：牵头文本模型评测方案设计，开发 API 性能评测工具，支持多模型对比、延迟与输出速度分析及可视化报告。
- **客户技术验证**：针对 Maxinsight 视频标注需求，完成 **40 组模型与推理配置评测**，输出效果、用量和性能分析；开发图像及具身数据标注 Demo，支持客户验证与销售演示。
- **海外模型授权合作**：参与 AWS、Together AI、Nebius、Modal 等伙伴的 Qwen 商业授权推进，梳理客户需求、模型范围、部署支持及收费方案，形成合作与决策材料。
- **模型接入与问题排查**：建设文本、多模态和语音调用样例，排查客户视频生成限流问题，提出配额调整与重试策略建议。

Plaud AI | LLM 应用算法工程师 (2024.11 – 2026.08)

负责 Plaud AI 背后的 AI 服务，覆盖 **录音总结、RAG 问答、项目级摘要、MCP / Agent 集成** 四条业务线，纵向贯穿「Model Hub 底层路由 / 容错 / 可观测性 → 上层 Multi-Agent 业务编排」全栈。

Plaud Project Summary — Multi-Agent 项目级摘要服务（独立负责,端到端）

从 0 到 1 独立交付并上线：聚合一个项目下的多份录音与文档，产出结构化项目报告，支持总结 / 对比 / 进度跟踪三种策略。

- **Agent 工作流编排 (DeepAgents + LangChain)**：按 token 量静态路由 ONE-PASS / MAP-REDUCE；主链「分析文件关系 → 生成大纲 + 抽 RAG 查询 → 检索补全 → 合成 → 审阅润色」串成工具流；大内容委托 map-reduce 子 Agent(context 隔离)，先按文件并行抽取 section、再按 section 维度并行合并(维度转换实现去重)，最后组装；并发写 state 用 reducer 合并防数据竞争
- **Agent 健壮性工程**：System prompt 定序 + 工具限流防死循环，review 后锁写防覆盖；文件预处理先生成 file_summary，Agent 看摘要而非全文，从源头压低 context
- **Temporal 外部服务接入 + K8s 优雅关停**：上游 Workflow HTTP 触发即返 202，后台 asyncio 算完用 Temporal Signal 异步回传；SIGTERM 后先摘流(健康检查转 503)、排空在途任务再退出，保证长任务不被腰斩
- **Citation 引用溯源**：LLM 内短 ID 省 token，出口三级模糊匹配还原(精确 → endswith → contains)并映射回文件名，纯 Python 确定性处理，不过 LLM
- **自研评测体系 (G-Eval)**：三种策略各配加权维度，每维度多采样(N=8)取均值，LLM-as-Judge(gpt-5.1)让 prompt 改动可量化对比

Plaud Model Hub — 统一 LLM 调用基础设施（核心贡献者）

公司所有 LLM 调用的底座，统一接入 OpenAI / Anthropic / Gemini / 火山 / DashScope / Bedrock 等多厂商。解决配额限制、成本优化、可用性 SLA 三重约束。支撑 Plaud-Summary / Plaud-Insight 等所有业务线，**日调用量 50 万次，P99 延迟 <800ms，可用性 100%**。

- **PassThrough 架构（核心设计）**：单一入口 invoke() 支持统一模式（Hub 标准字段翻译成各家 SDK）、同风格透传（零转换）、跨风格透传（Adapter 矩阵翻译 OpenAI ↔ Anthropic / Gemini / Bedrock），业务方无感切换厂商，三种模式共享同一套容错基础设施（路由 / 重试 / 熔断 / 插件）
- **自适应权重 + 权重重分配（调度算法核心）**：按 429 错误率渐进降权替代二值切流，保留 10% 下限作探测流量；权重重分配让应急 Endpoint 从 8% 升至 45% 真正承接流量；recovery_rate 限速恢复防流量瞬涌再次 429。**GSU(80%) + PayGo(20%) 配置下流量平滑转移，单月节省成本 $1200+**
- **三层容错 + 健康管理闭环**：Retry（429 按 Retry-After 退避 / 5xx 指数退避）→ Failover（换同模型 Endpoint）→ Fallback（换备选模型保留 passthrough 字段）；熔断器（5xx/超时三状态机）+ 限流器（429 解析 Retry-After）+ 自适应权重（429 降权）三种健康信号分工协同；每次调用成功/失败回写滑窗，下次路由前重新计算排除集 + 权重
- **可观测性与工程化**：插件系统两层钩子（请求级 + 尝试级）；Langfuse 全链路追踪（token / 耗时 / 错误率 / 成本）；自适应权重告警（multiplier 跌破阈值触发 WARNING / CRITICAL）；YAML 配置驱动 + AWS AppConfig 热加载，业务方改配额/切模型零代码改动

Plaud Summary — AI 录音总结服务（核心业务,除 Mark Note 外全链路参与）

把录音转写变成结构化 Markdown 笔记。覆盖海外 / CN 多 Region、多语种、50+ 业务场景；底层依赖 Kafka (MSK) 异步消费 + FastAPI + Model Hub + Langfuse 全链路追踪。

- **「JSON → Reasoning One-Shot」总结链路重构（最大收益项）**：Markdown 直出释放被强 schema 吃掉的 reasoning output budget；配合长文本 map-reduce、十余场景 One-Shot 模板，**已上线为默认管道**；自研 G-Eval 评估体系（六维度加权 + LLM-as-Judge）让 Prompt 改动可量化对比，**评测分从 30% 提升至 70+%**
- **知识库模板（PFS）三步管道**：近 30 个专业场景走 **Framework → Sections → Polish** 产出专家级笔记；框架步 LLM 动态生成结构并自检，分节步并行抽取（max_concurrency=7），润色步用文本 diff 比例（阈值 0.10）防摆烂并重试；每步独立选模型 + fallback，**评测分从 70+% 提升至 80+%**
- **总结头图生成（Summary Card）**：LLM 生成 HTML（非黑盒生图）→ 浏览器渲染 → S3 归档；1200+ 行设计指南 + 前置拦截 6 类 AI 翻车（分隔符错误 → 布局崩坏、嵌套 grid 缺 col-span-12）；独立渲染服务（Node.js + Playwright）可扩容，多语言字体自动切换 + CN 区域 AIGC 合规
- **工程化与生态**：User-Custom Prompt 污染治理（正则门控 + 小模型复核防出处泄露）；模板推荐（Milvus 向量相似度）+ 审核状态机；Persona 个性化（onboarding 问卷生成画像调整表达风格）

Plaud Ask — RAG 问答

独立从 0 到 1 交付 Integration Skills(Gmail + Google Docs + Slack)：LLM 起草可编辑卡片、用户审阅后经 MCP 投递；覆盖 API → Handler → Checkpoint → MCP Client 全栈；同时长期负责推荐问题、多语言治理、Embedding 工程化。

- **卡片不污染 LLM 上下文**：分「展示」与「LLM 推理」两通道，避免模型把自己草稿当用户发言反向引用
- **配置驱动 Handler + 双状态机**：注册表 + builder 替代 if/elif，新技能只追加配置；按 MCP 工具数路由三模式；卡片态 / 投递态分离，部分失败仍标成功
- **Email 链 + MCP Client**：转写 → Markdown → PDF → 投递 PDF 失败非阻断；S3 key 换 presigned URL 让远端 LLM 读图；1500+ 行单测覆盖原子性 / OAuth / 部分失败

腾讯（深圳）| 前端开发工程师（腾讯文档） (2020.06 – 2022.06)

- **域代码格式标准化**：制定数据规范，重构数据 / 排版 / 业务三层架构 100% 兼容 OOXML；首次实现排版引擎域代码自动断行(行业领先)
- **腾讯文档 Drive 研发**：设计视图 / 控制 / 状态 / 网络四层架构，打通移动端文件云端导入 / 存储 / 在线编辑
- **研发效能建设**：封装 Word 引擎 API、升级团队自动化测试框架，从 0 编写性能测试用例(首屏 / 大文档 / 协同)；团队荣获**公司研发效能奖**

专业技能

类别	技术栈
语言	Python, TypeScript / JavaScript, SQL, C#
LLM / Agent	LangChain, LangGraph, DeepAgents, LlamaIndex, MCP, Langfuse, Ragas
模型与推理	Gemini (Vertex AI), GPT (OpenAI), Claude (Bedrock), 豆包 / 通义 (Model Hub)
后端框架	FastAPI, Flask, Gunicorn / Uvicorn, NiceGUI, Gradio
数据 / 存储	AWS S3, OpenSearch, Milvus, pgvector, Redis, MySQL, MongoDB, Snowflake, Redshift
基础设施	Docker, K8s, Supervisor, Temporal, Kafka (MSK), AWS AppConfig
可观测性	OpenTelemetry, Langfuse, 自定义业务指标
工程工具	uv, Ruff, MyPy, Pre-commit, Git, Linux

开源 & 个人项目

text-to-diagrams | 纯文本一键生成「带 SVG 配图」的 Markdown (2026.05)

Python 库 + Claude Skill plugin + FastAPI 服务（Docker 一键起），自动为技术文档 / 学习笔记配图。覆盖架构图 / 流程图 / 状态机 / 数据流等 17 种图类型。

- **核心设计：LLM 只做「理解 + 摆放」，不算坐标**：10 种有公式 / 确定性布局的图（树 / 矩阵 / timeline / Sankey）走纯 Python 几何计算，7 种自由拓扑图（架构 / 流程）走 LLM 改 SVG；分工明确避免 LLM 在数学计算上幻觉
- **两层防幻觉护栏**：① 锚点 ID 对照大纲校验（编造节点 → 重生成）；② SVG 输出纯 Python 几何校验（坐标越界 / 重叠 → 反馈重试），成本 +30% 换准确率
- **可插拔多产物形态**：主产物 SVG 图 + 第二产物 Summary Infographic（结论先行文本抽成 8 种原语，按注意力金字塔拼 HTML 信息图）；API mode 参数共存，**删子包即下线**，架构解耦

企业知识库检索与问答系统 (RAG)(2024.04 – 2024.08)

- 扩展开源框架支持多格式文档（doc、扫描版 PDF、图片）；自研版面排序算法优化复杂版面分析与 Markdown 转换；
- 落地查询转换、混合搜索、Graph 增强等策略；用 Ragas 量化评估迭代配置。